

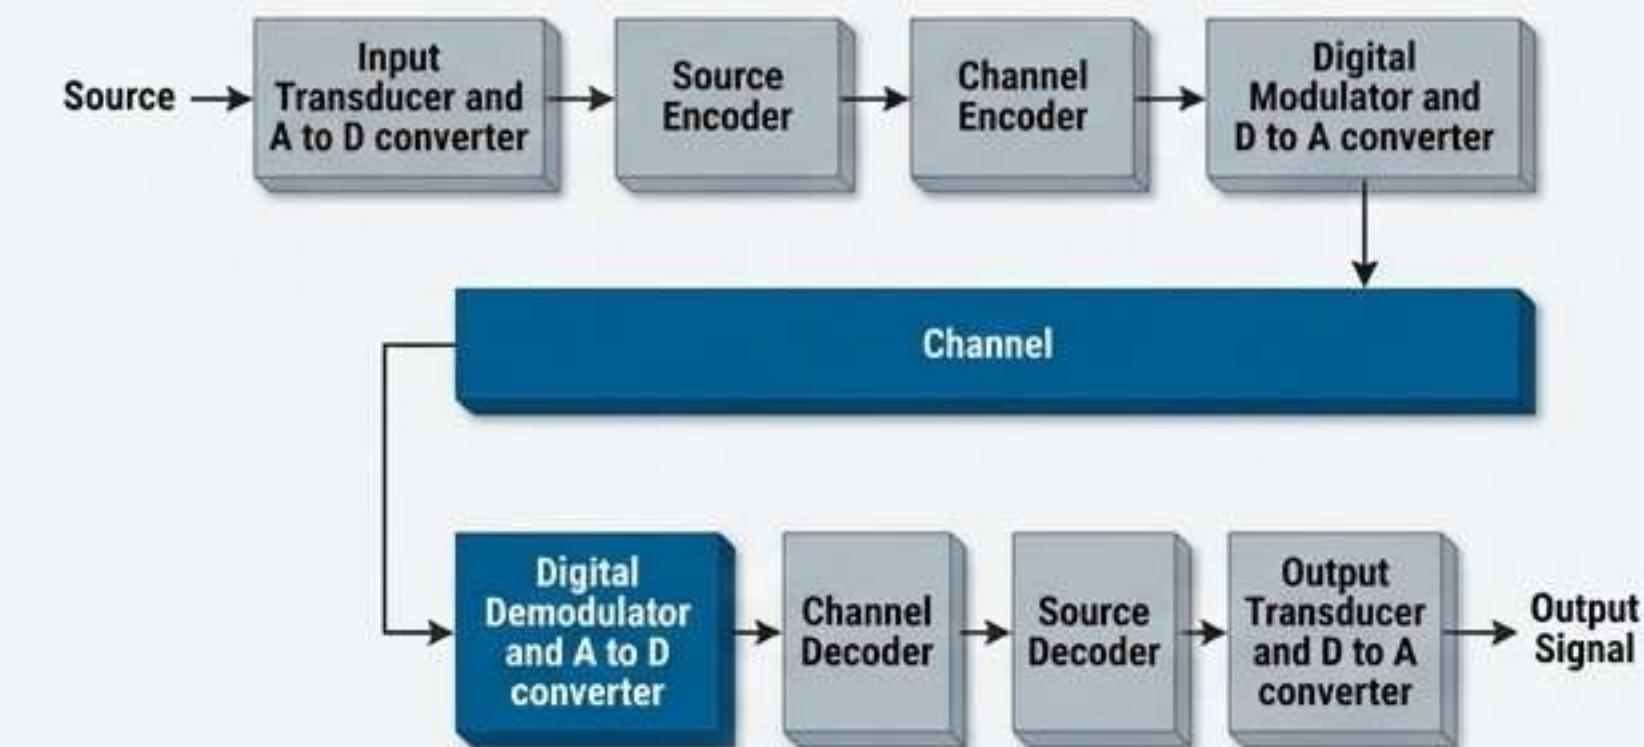
Ανίχνευση Ψηφιακών Σημάτων με Νευρωνικά Δίκτυα

Μια Μελέτη σε Διαμορφώσεις BPSK & QPSK για Κανάλια AWGN
και Rayleigh Fading με Ατελή Γνώση Καναλιού (Imperfect CSI)

Η Κεντρική Πρόκληση: Από το Λαμβανόμενο Σήμα στα Αρχικά Bits

Σε κάθε ψηφιακό σύστημα επικοινωνιών, ο πομπός στέλνει μια ακολουθία bits, αλλά ο δέκτης δεν τα λαμβάνει ποτέ «καθαρά». Το σήμα αλλοιώνεται από θόρυβο και από τις ατέλειεις του καναλιού διάδοσης.

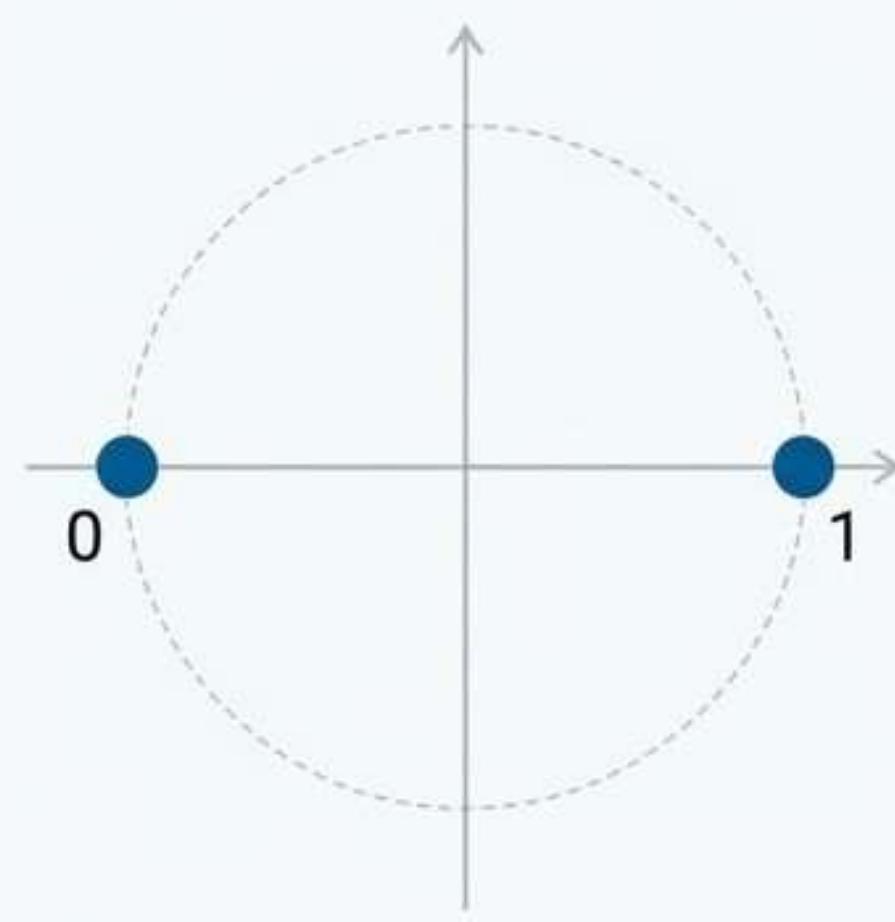
Ο ρόλος του δέκτη είναι να αποφασίσει ποια ακολουθία bits στάλθηκε αρχικά. Αυτή η διαδικασία ονομάζεται ανίχνευση συμβόλων (**symbol detection**) και είναι καθοριστική για την απόδοση του συστήματος.



Η Γλώσσα των Bits: Διαμορφώσεις BPSK και QPSK

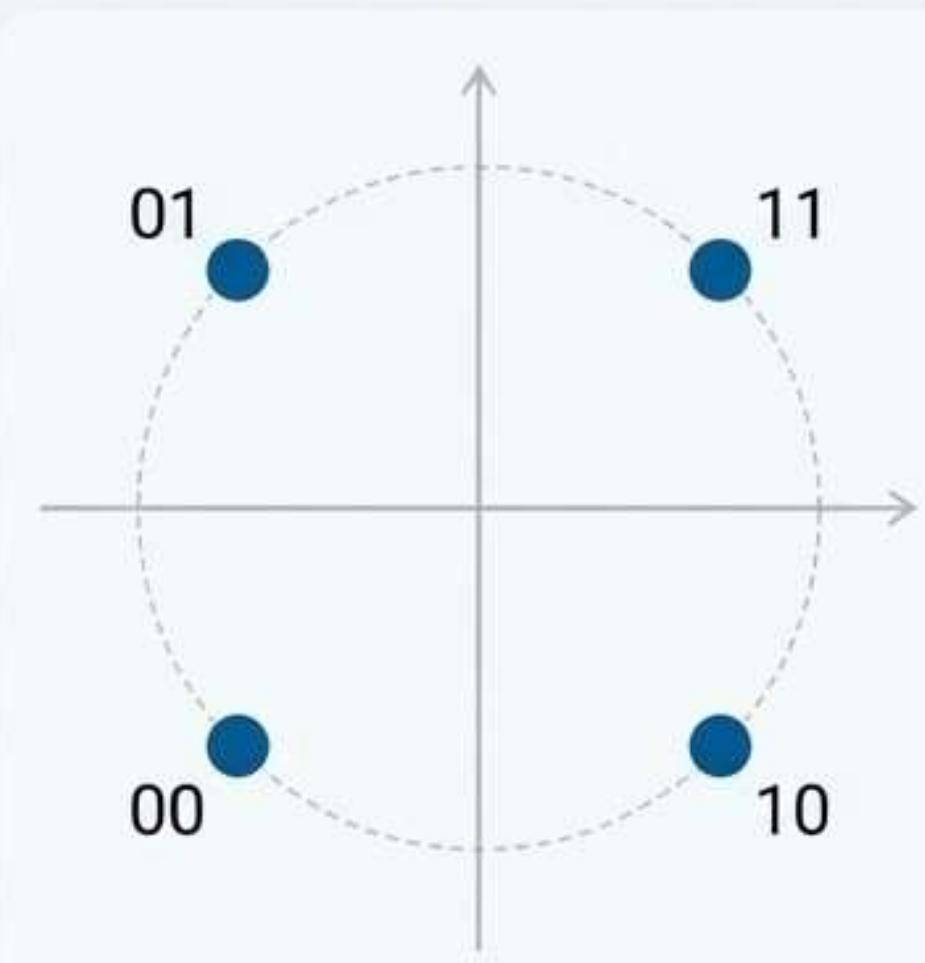
BPSK (Binary Phase Shift Keying)

- Κάθε bit αντιστοιχίζεται σε ένα σύμβολο (π.χ., bit '0' -> -1, bit '1' -> +1).
- Μεταφέρει 1 bit ανά σύμβολο.
- Απλή και ανθεκτική.



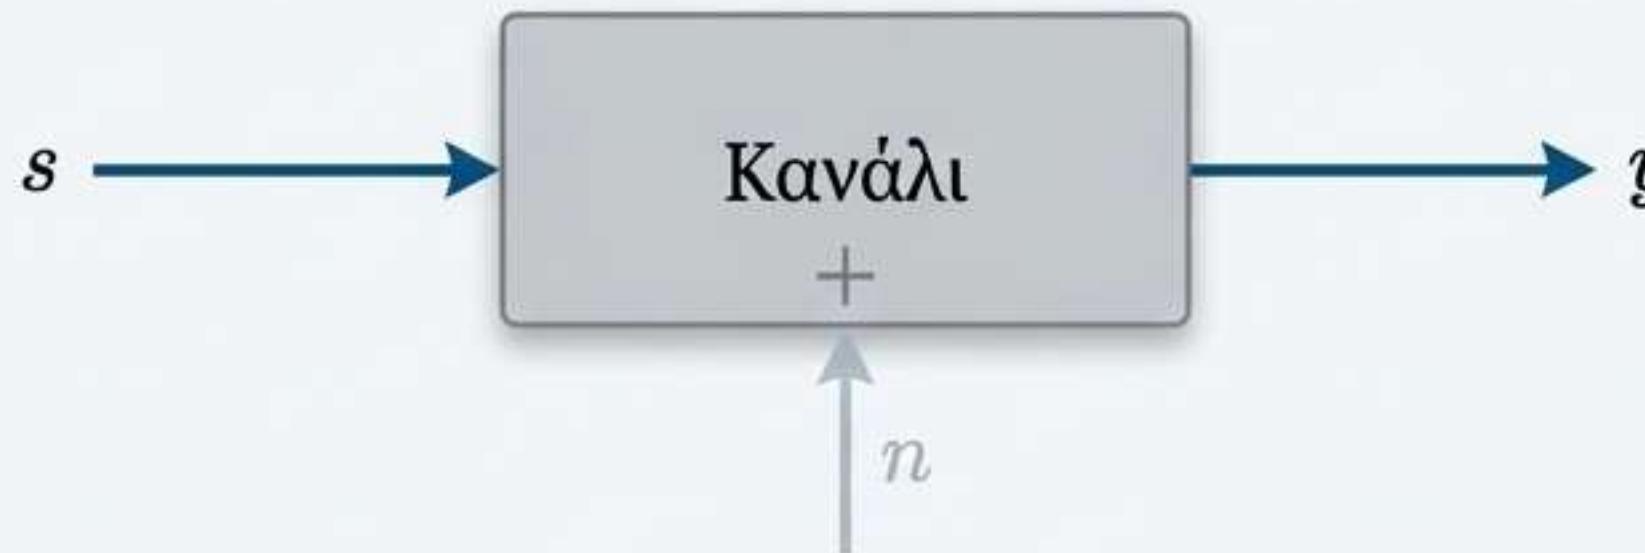
QPSK (Quadrature Phase Shift Keying)

- Κάθε ζεύγος bits αντιστοιχίζεται σε ένα σύμβολο σε δύο διαστάσεις (I/Q).
- Μεταφέρει 2 bits ανά σύμβολο.
- Μεγαλύτερη φασματική αποδοτικότητα.



Το Ιδανικό Περιβάλλον: Το Κανάλι AWGN

Αρχικά, εξετάζουμε το κανάλι AWGN (Additive White Gaussian Noise). Σε αυτό το μοντέλο, η μοναδική πηγή αλλοίωσης είναι ο προσθετικός λευκός Γκαουσιανός θόρυβος.

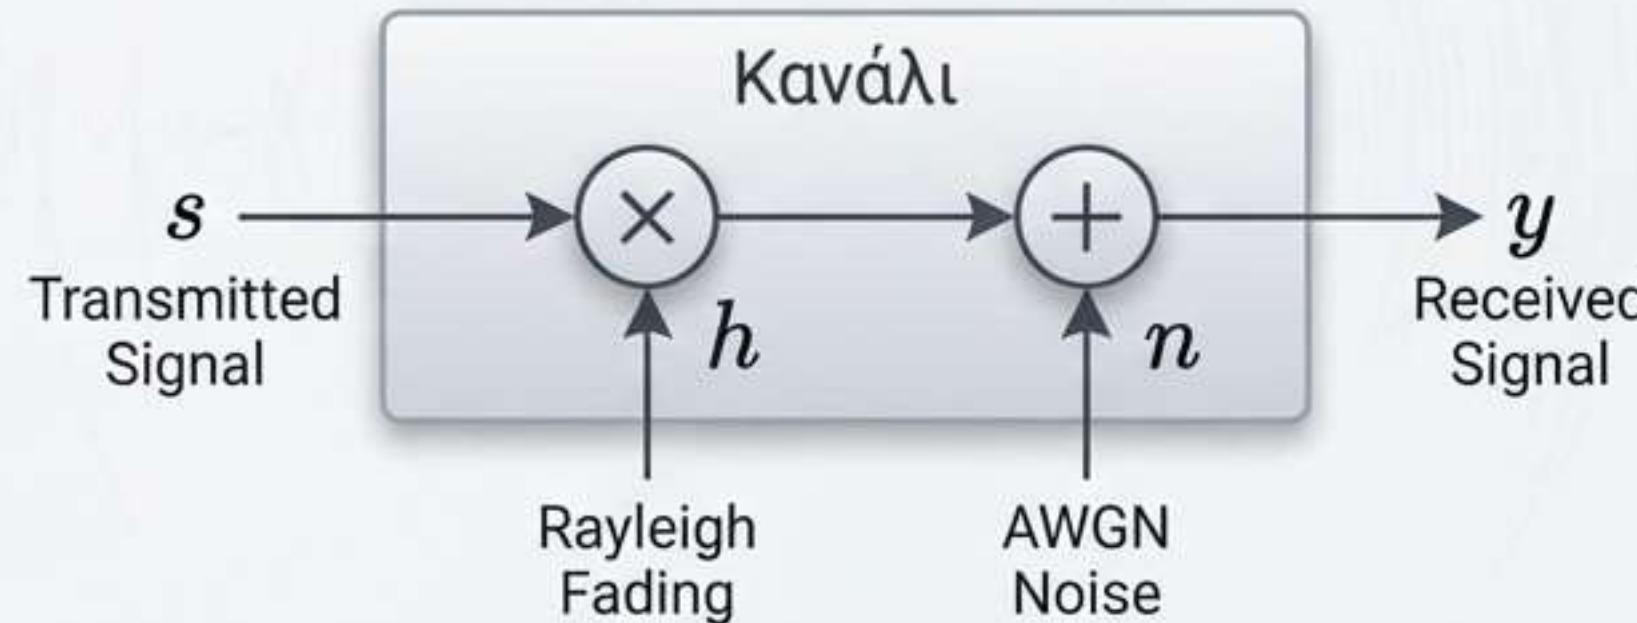


$$y = s + n, \text{ όπου } s \text{ είναι το εκπεμπόμενο σύμβολο και } n \text{ είναι ο θόρυβος με κατανομή } N(0, \sigma^2).$$

Ο Βέλτιστος Κανόνας: Σε αυτό το περιβάλλον, η θεωρία παρέχει έναν βέλτιστο ανιχνευτή: τον ανιχνευτή Μέγιστης Πιθανοφάνειας (Maximum Likelihood), ο οποίος υλοποιείται με έναν απλό κανόνα απόφασης (π.χ., έλεγχος προσήμου).

Η Πραγματικότητα Γίνεται Περίπλοκη: Το Κανάλι Rayleigh Fading

Σε ρεαλιστικά σενάρια (π.χ., ασύρματες επικοινωνίες), το σήμα επηρεάζεται επιπλέον από διαλείψεις (fading) λόγω πολλαπλών διαδρομών και ανακλάσεων. Το μοντέλο Rayleigh Fading περιγράφει αυτό το φαινόμενο.

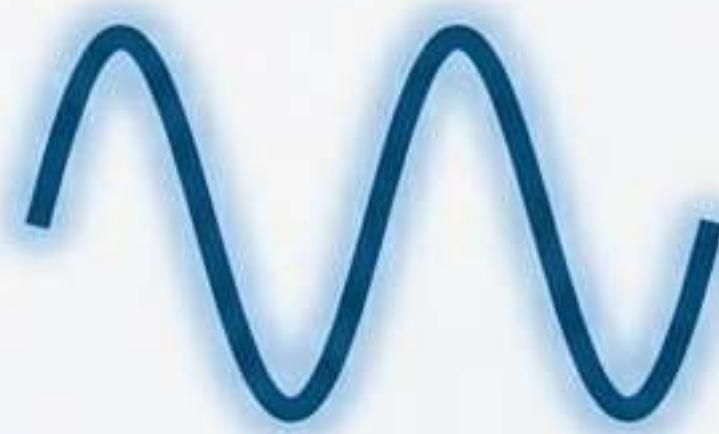


$y = hs + n$, όπου h είναι ένας τυχαίος, μιγαδικός συντελεστής που αντιπροσωπεύει την επίδραση του καναλιού. Το σήμα μπορεί να εξασθενεί ή να ενισχύεται τυχαία.

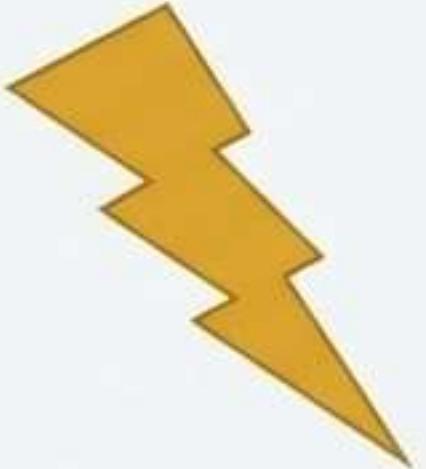
Συνέπεια: Η ανίχνευση γίνεται σημαντικά πιο απαιτητική.

Το Κρίσιμο Σφάλμα: Ατελής Γνώση Καναλιού (Imperfect CSI)

Για να αντισταθμίσει τις διαλείψεις, ο δέκτης πρέπει να γνωρίζει τον συντελεστή h (Channel State Information - CSI). Στην πράξη, ο δέκτης διαθέτει μόνο μια εκτίμηση του καναλιού, \hat{h} , η οποία περιέχει σφάλμα: $\hat{h} = h + e$.



Πραγματικό Κανάλι h
(True CSI)



Σφάλμα Εκτίμησης e
(Estimation Error)



Εκτιμώμενο Κανάλι \hat{h}
(Estimated CSI)

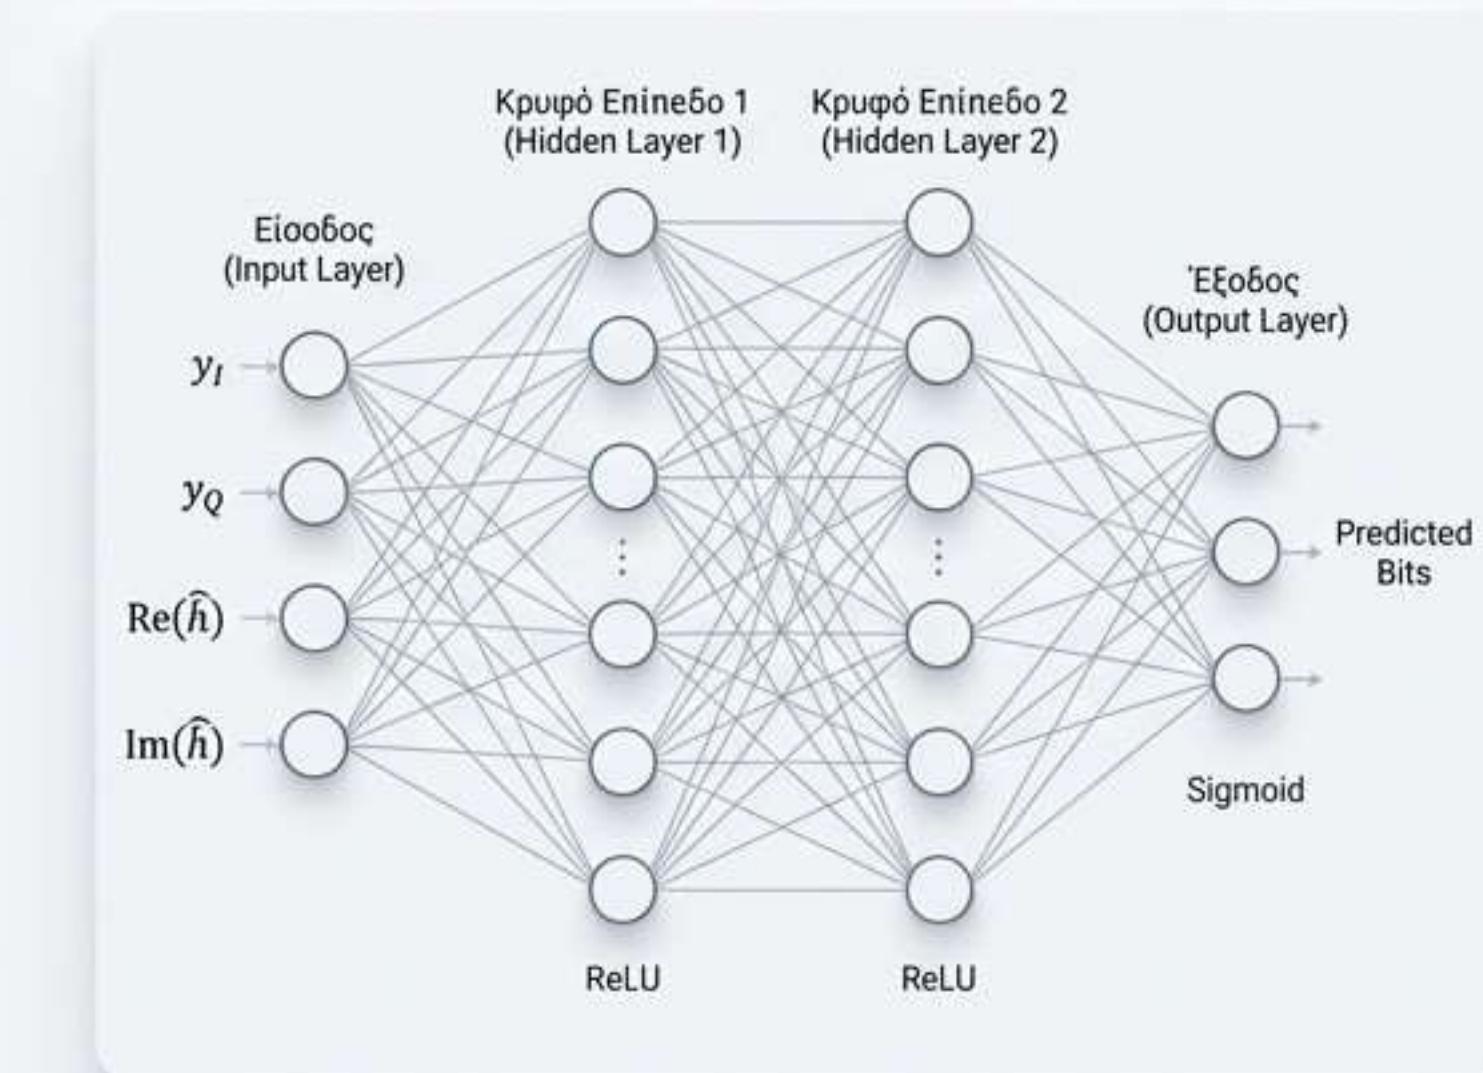
Ο κλασικός δέκτης χρησιμοποιεί την εκτίμηση \hat{h} σαν να ήταν η πραγματική τιμή h . Αυτή η ασυμφωνία (mismatch) οδηγεί σε υποβέλτιστη απόφαση και αυξημένα σφάλματα bit (BER). Αυτός είναι ο ανιχνευτής που θέλουμε να ξεπεράσουμε.

Η Λύση της Μηχανικής Μάθησης: Ο Νευρωνικός Δέκτης (MLP)

Αντί για έναν ανιχνευτή που βασίζεται σε αυστηρές μαθηματικές παραδοχές, υλοποιούμε έναν δέκτη βασισμένο σε ένα πολυεπίπεδο νευρωνικό δίκτυο (Multi-Layer Perceptron - MLP).

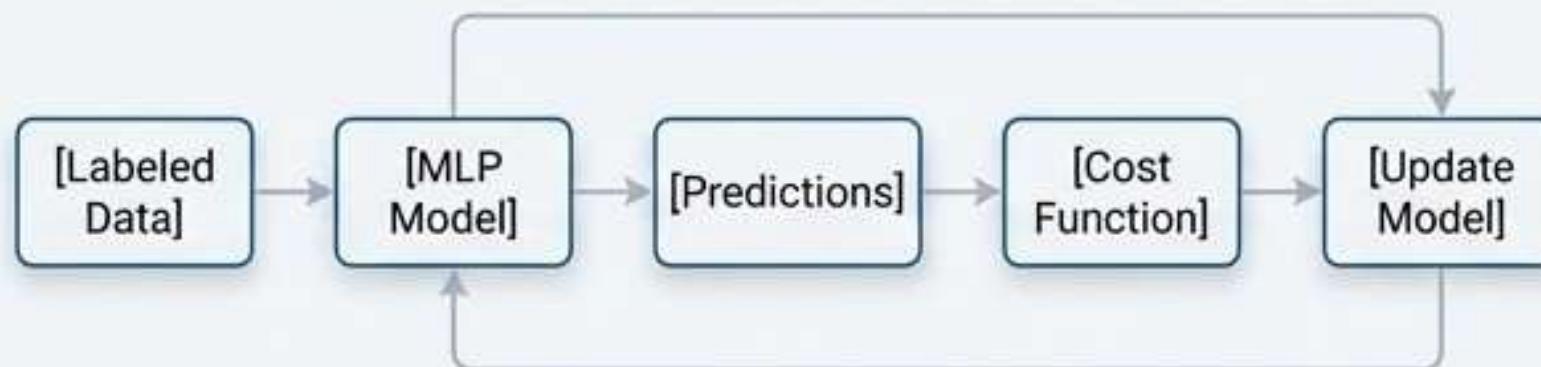
Αρχιτεκτονική (Architecture)

- **Είσοδος (Input):** Τα χαρακτηριστικά που δίνονται στο δίκτυο είναι το λαμβανόμενο σήμα y και (στην περίπτωση fading) η εκτίμηση καναλιού \hat{h} .
 - AWGN (QPSK): $X = [y_I, y_Q]$
 - Fading (QPSK): $X = [\text{Re}(y), \text{Im}(y), \text{Re}(\hat{h}), \text{Im}(\hat{h})]$
- **Έξοδος (Output):** Το δίκτυο εκπαιδεύεται να προβλέπει απευθείας τα εκπεμπόμενα bits (bit-wise απόφαση μέσω συνάρτησης Sigmoid).
- **Κρυφά Επίπεδα (Hidden Layers):** Χρήση συνάρτησης ενεργοποίησης ReLU.



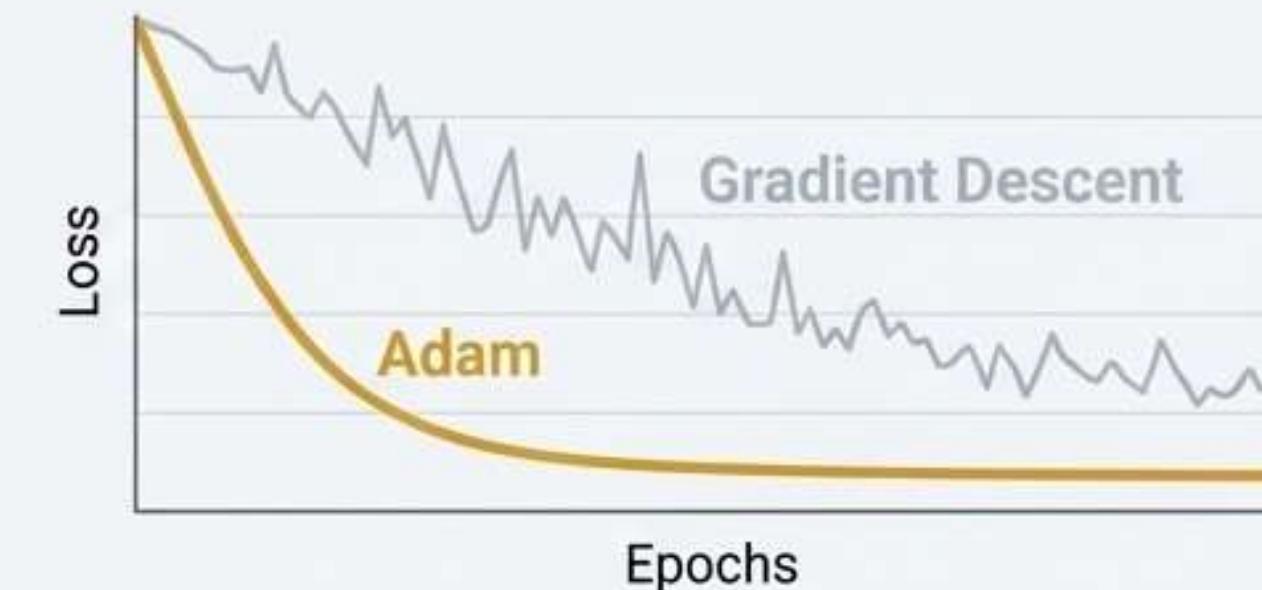
Η Διαδικασία Εκπαίδευσης: Μαθαίνοντας τον Κανόνα Απόφασης

Μέθοδος: Επιβλεπόμενη μάθηση
(Supervised Learning)



- **Συνάρτηση Κόστους:** Binary Cross-Entropy (BCE), κατάλληλη για προβλήματα δυαδικής ταξινόμησης (πρόβλεψη bit 0/1).
- **Στρατηγική:** Το μοντέλο εκπαιδεύεται σε δεδομένα που αντιστοιχούν σε έναν σταθερό λόγο σήματος προς θόρυβο (SNR), συγκεκριμένα στα 6 dB.

Βελτιστοποιητές (Optimizers)



- **Gradient Descent:** Ένας απλός, θεμελιώδης αλγόριθμος. Λειτουργεί ως baseline.
- **Adam Optimizer:** Ένας προσαρμοστικός αλγόριθμος που επιτυγχάνει ταχύτερη σύγκλιση και πιο σταθερή εκπαίδευση. Αποδεικνύεται καταλληλότερος για το πιο περίπλοκο σενάριο του fading.

Δοκιμή 1: Στο Ιδανικό Κανάλι AWGN, το MLP Ισοφαρίζει τον Βέλτιστο Ανιχνευτή

Observation

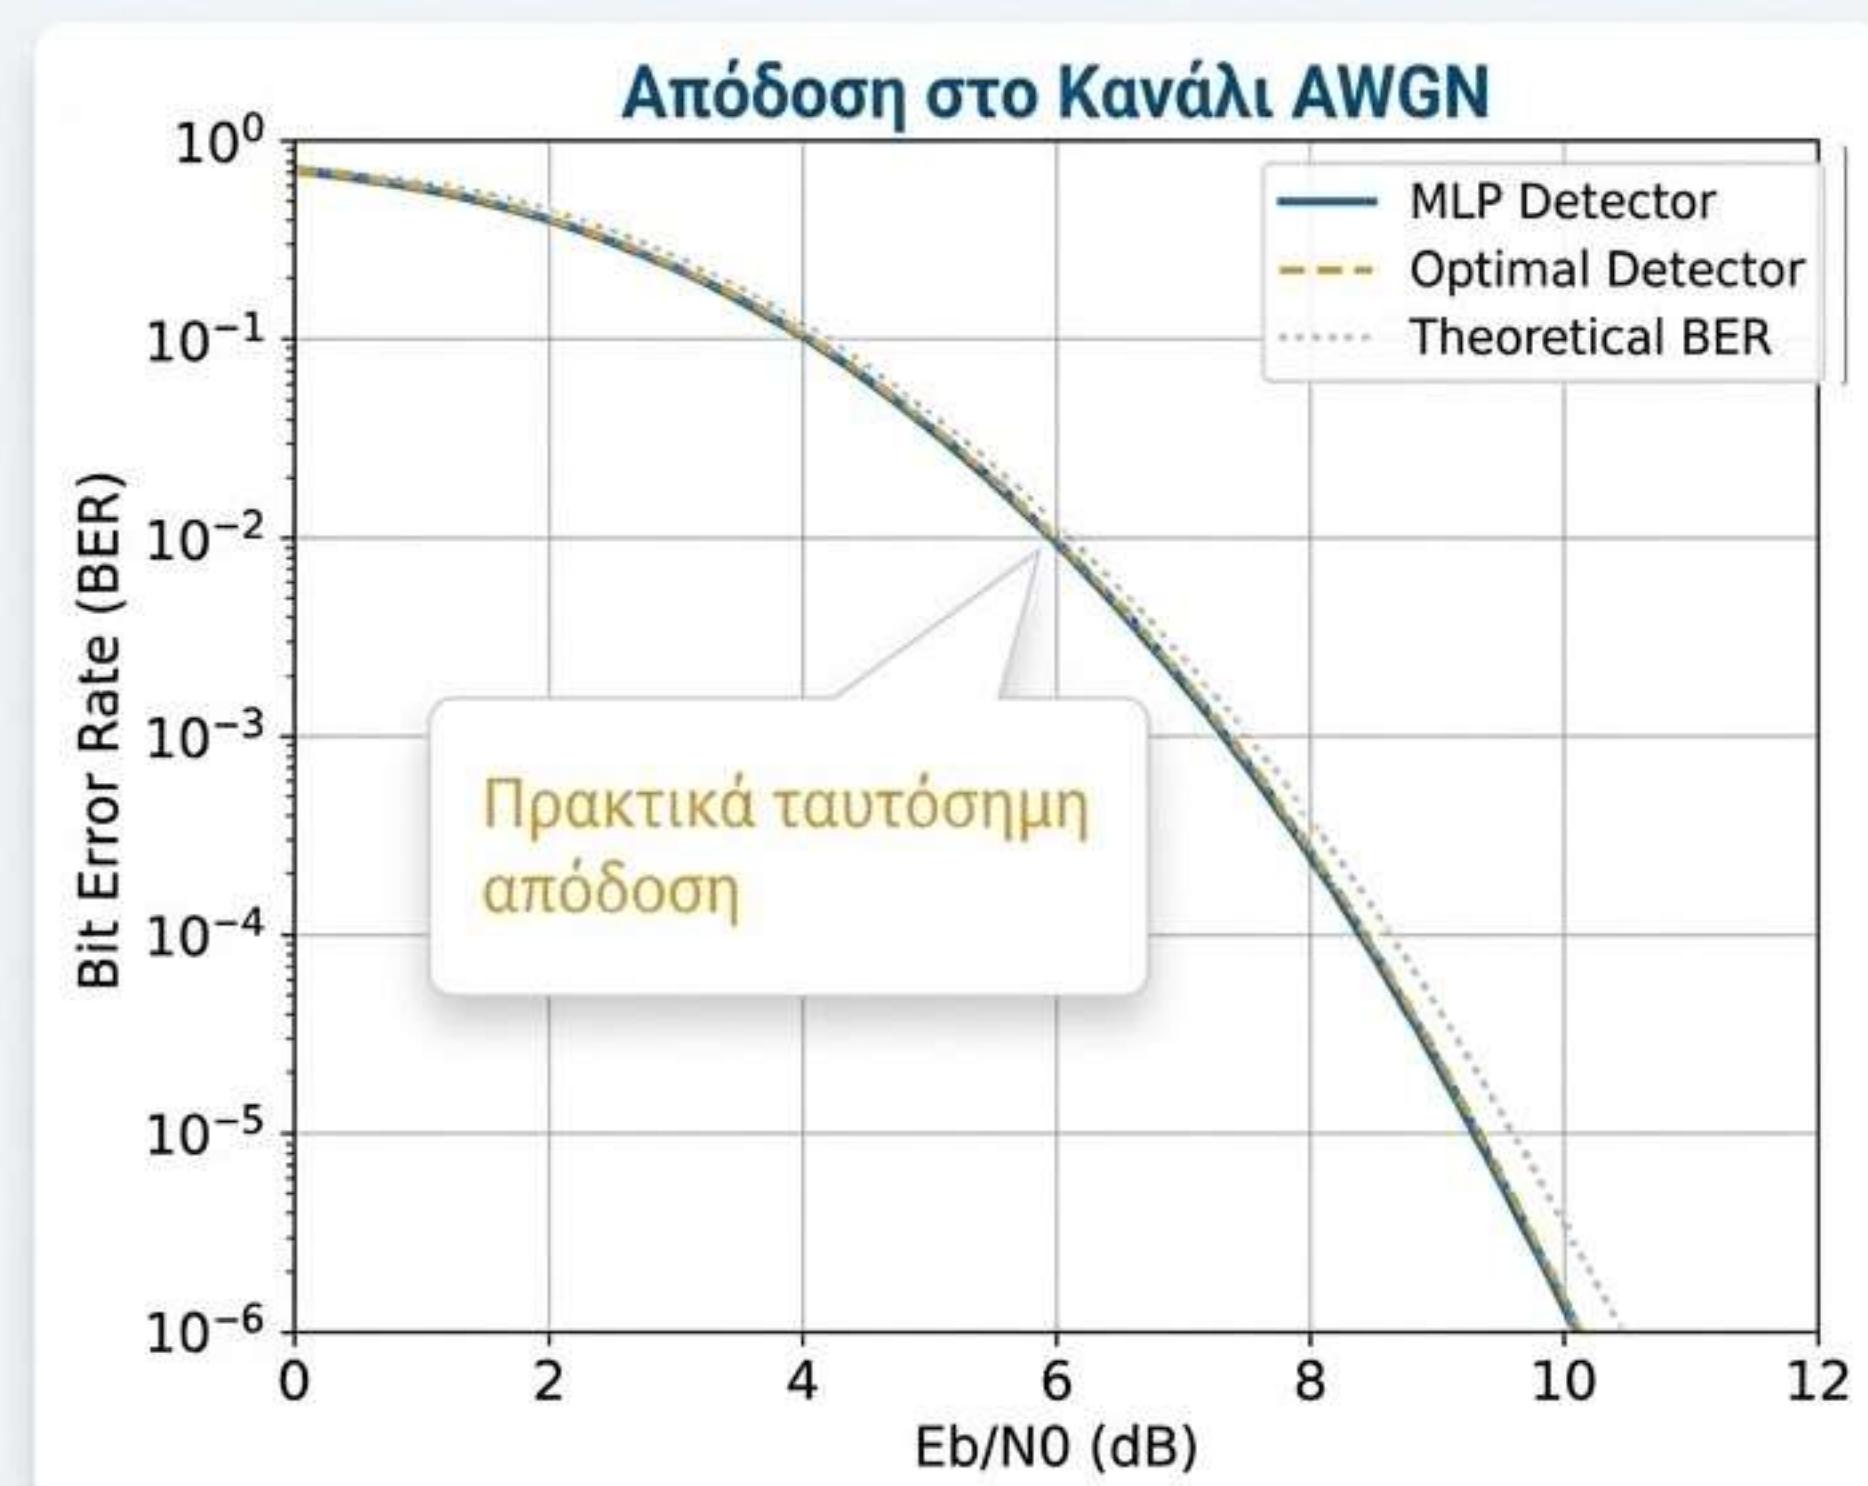
Στο περιβάλλον AWGN, το MLP μαθαίνει με επιτυχία τον **βέλτιστο κανόνα απόφασης** (sign rule).

The Evidence

Οι καμπύλες **Απόδοσης Σφάλματος Bit** (BER) του νευρωνικού δέκτη ταυτίζονται σχεδόν απόλυτα με τις καμπύλες του θεωρητικού βέλτιστου ανιχνευτή.

Conclusion

Αυτό επιβεβαιώνει την ορθότητα της προσέγγισης και αποδεικνύει ότι το MLP μπορεί να **αναπαράγει** την **κλασική βέλτιστη λύση** όταν αυτή υπάρχει.



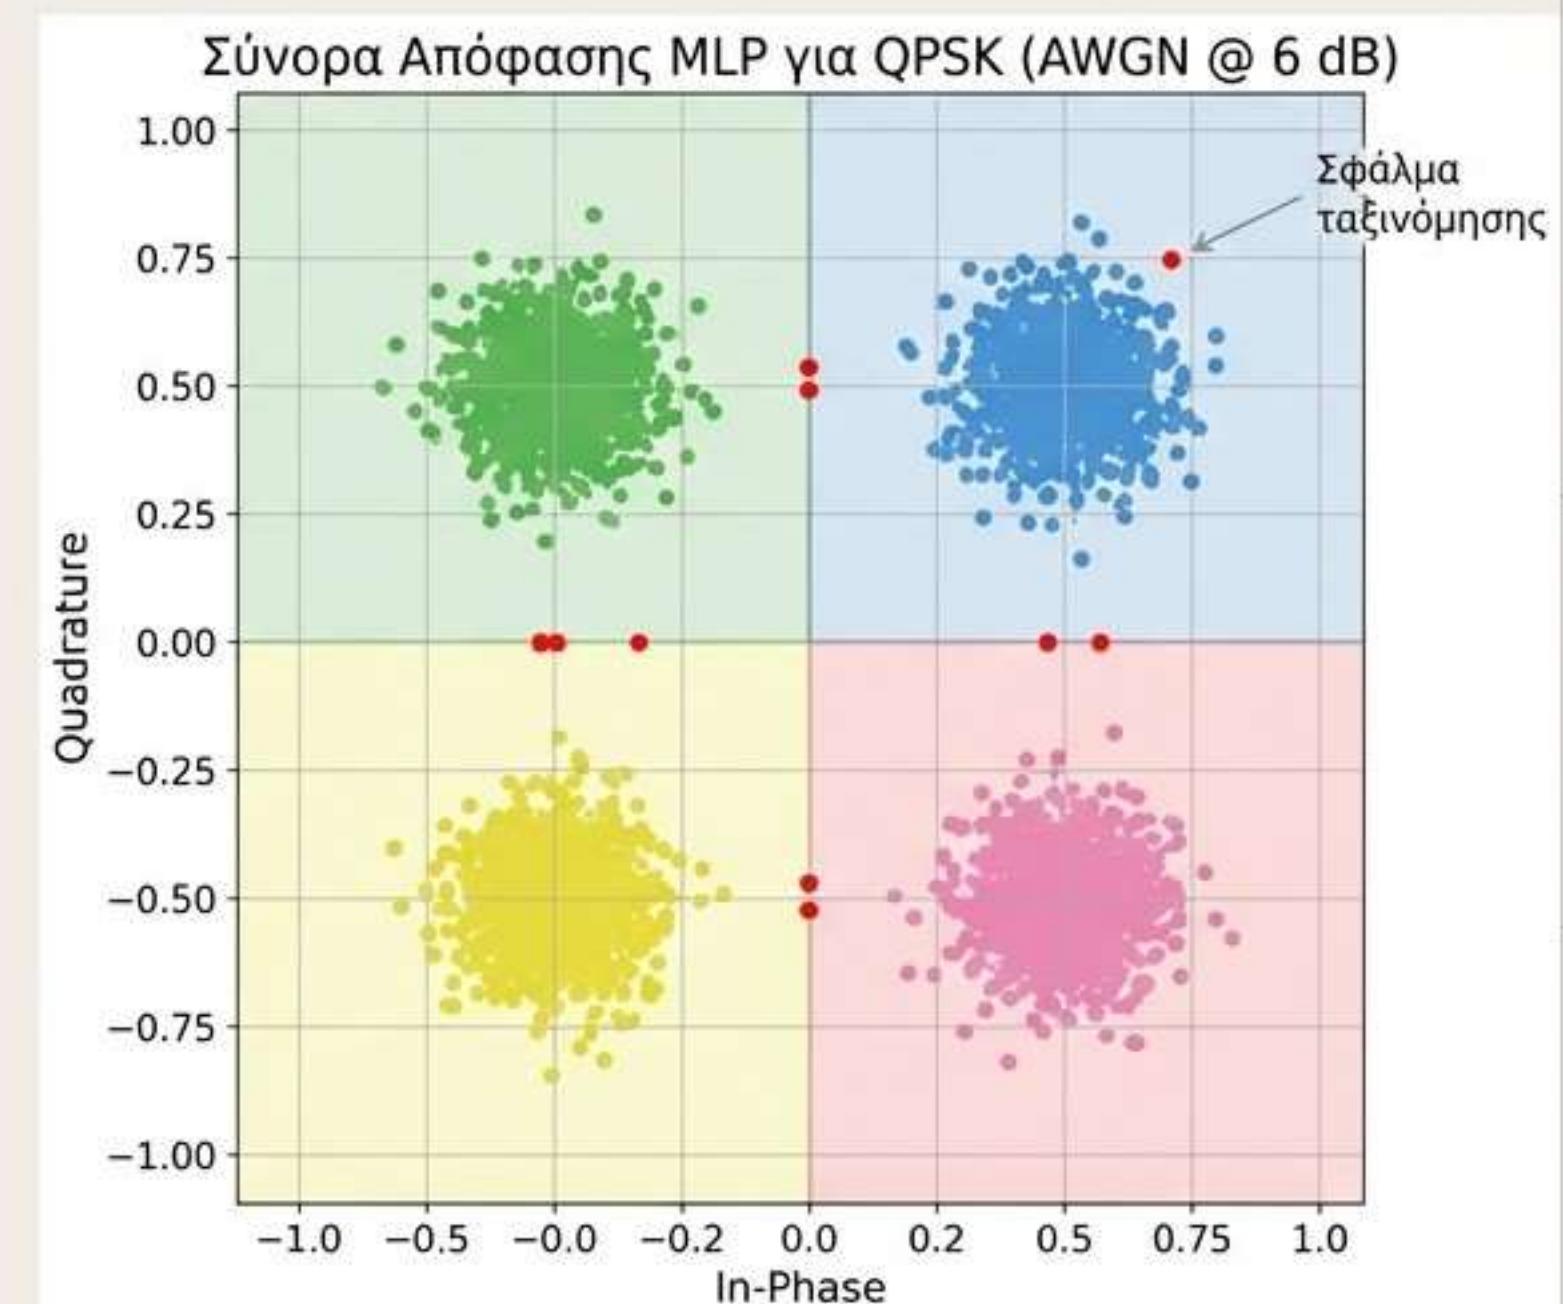
Οπτικοποίηση της Απόφασης: Πώς το MLP 'Βλέπει' τα Δεδομένα

Description

Τα διαγνωστικά γραφήματα απόφασης μας επιτρέπουν να δούμε πώς το εκπαιδευμένο MLP ταξινομεί τα σημεία του αστερισμού QPSK που έχουν αλλοιωθεί από θόρυβο (στο εκπαιδευτικό SNR των 6 dB).

Analysis

- Το γράφημα δείχνει καθαρά τα τέσσερα 'σύννεφα' των θορυβωδών συμβόλων.
- Το MLP έχει μάθει ένα **σύνορα απόφασης** που αντιστοιχεί στους άξονες $x=0$ και $y=0$, ακριβώς όπως και ο **βέλτιστος ανιχνευτής**.
- Τα σημεία με **λάθος χρώμα** (σφάλματα) βρίσκονται κυρίως κοντά στα σύνορα απόφασης, όπως αναμένεται.



Δοκιμή 2: Σε Ρεαλιστικές Συνθήκες Fading, το MLP Υπερτερεί του Κλασικού Ανιχνευτή

The Scenario

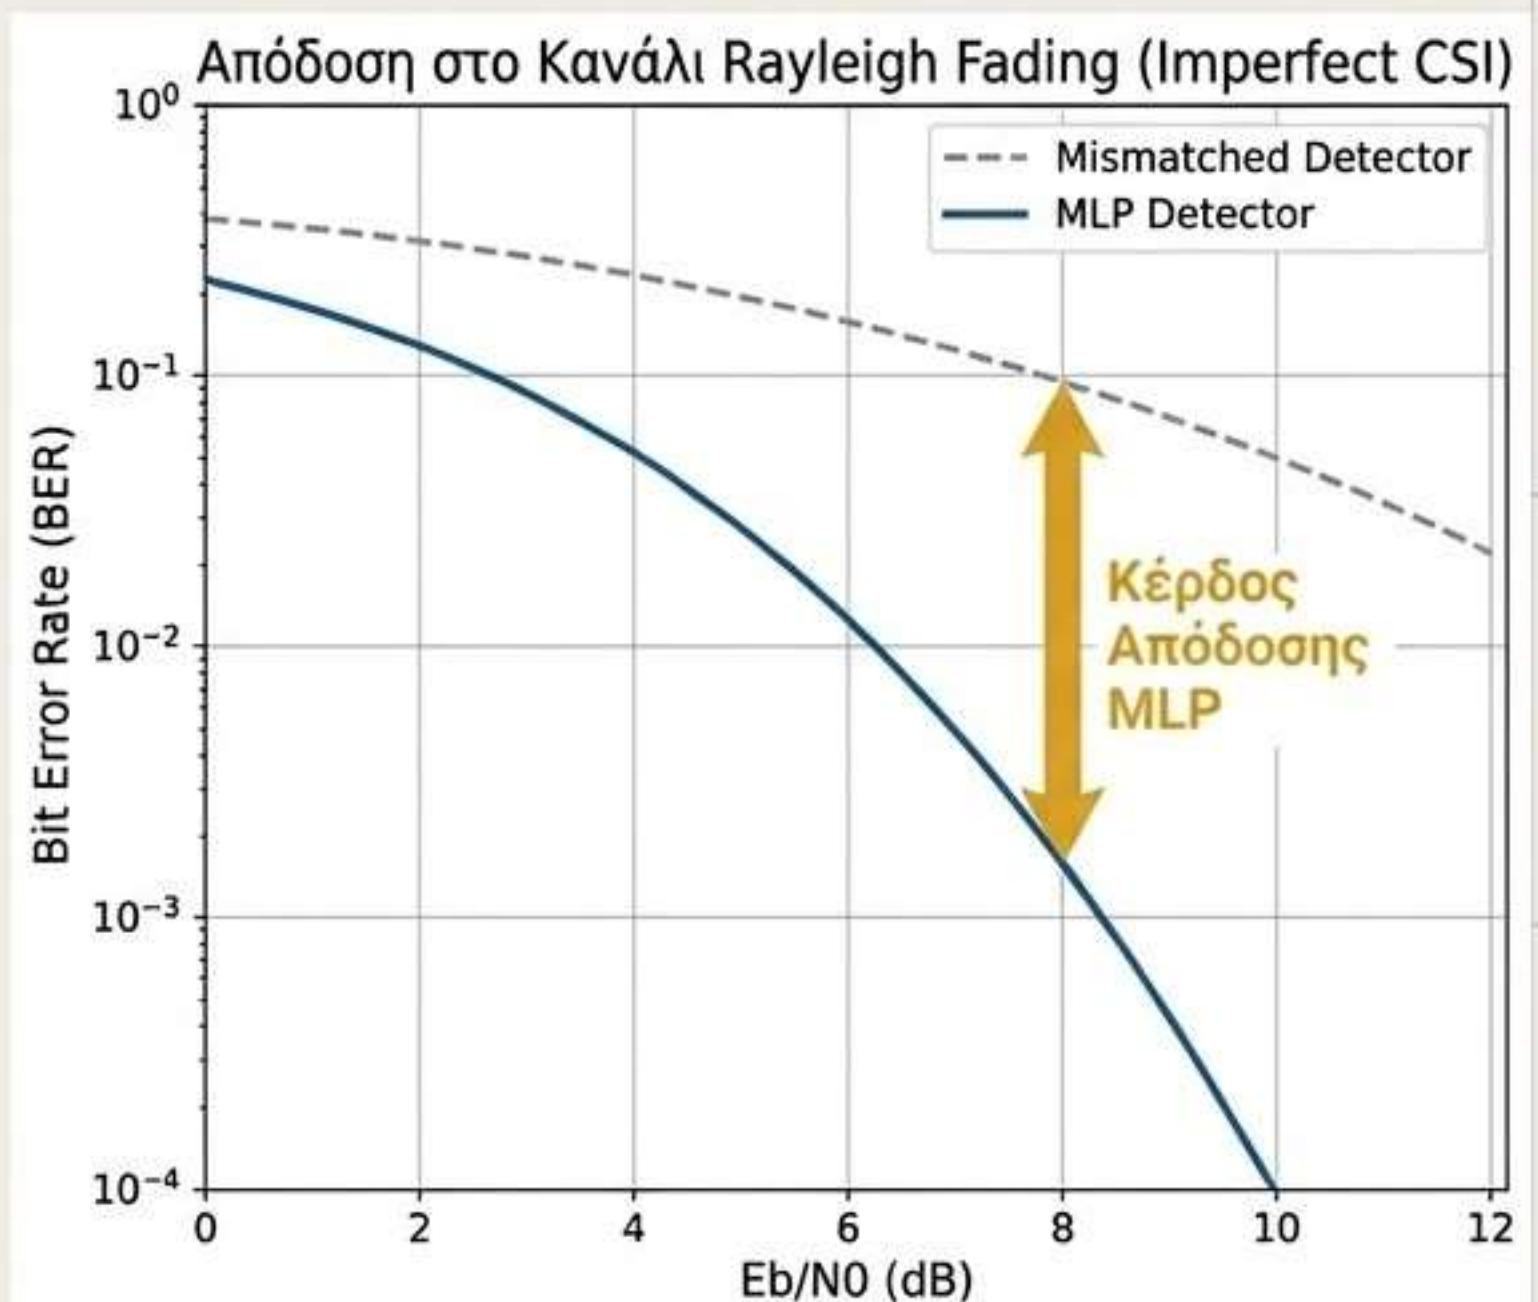
Εδώ, συγκρίνουμε την απόδοση του νευρωνικού δέκτη (MLP) έναντι του κλασικού 'mismatched' ανιχνευτή, ο οποίος αγνοεί το σφάλμα στην εκτίμηση του καναλιού (\hat{h}).

The Result

Η καμπύλη BER του MLP βρίσκεται σταθερά κάτω από την καμπύλη του mismatched detector. Αυτό σημαίνει ότι για τον ίδιο λόγο σήματος προς θόρυβο, ο νευρωνικός δέκτης επιτυγχάνει σημαντικά μικρότερο ποσοστό σφαλμάτων.

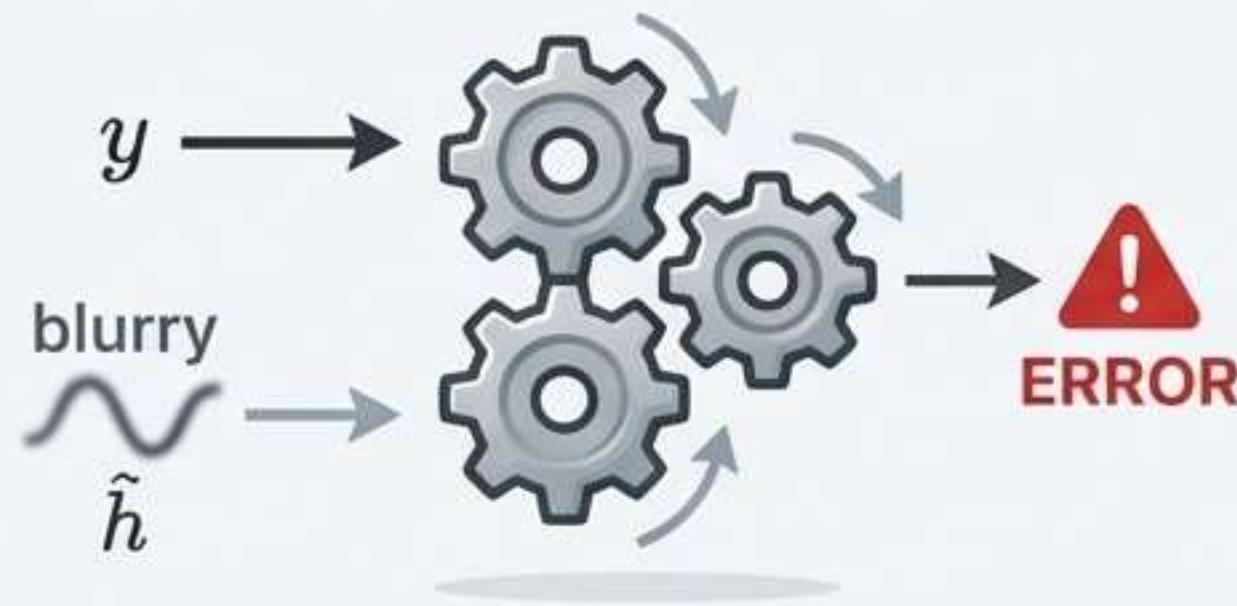
Conclusion

Το MLP έμαθε έναν πιο ανθεκτικό κανόνα απόφασης που μπορεί να διαχειριστεί την αβεβαιότητα της ατελούς γνώσης καναλιού.



Γιατί Υπερτερεί το MLP; Από την Άκαμπτη Λογική στην Ευφυή Προσαρμογή

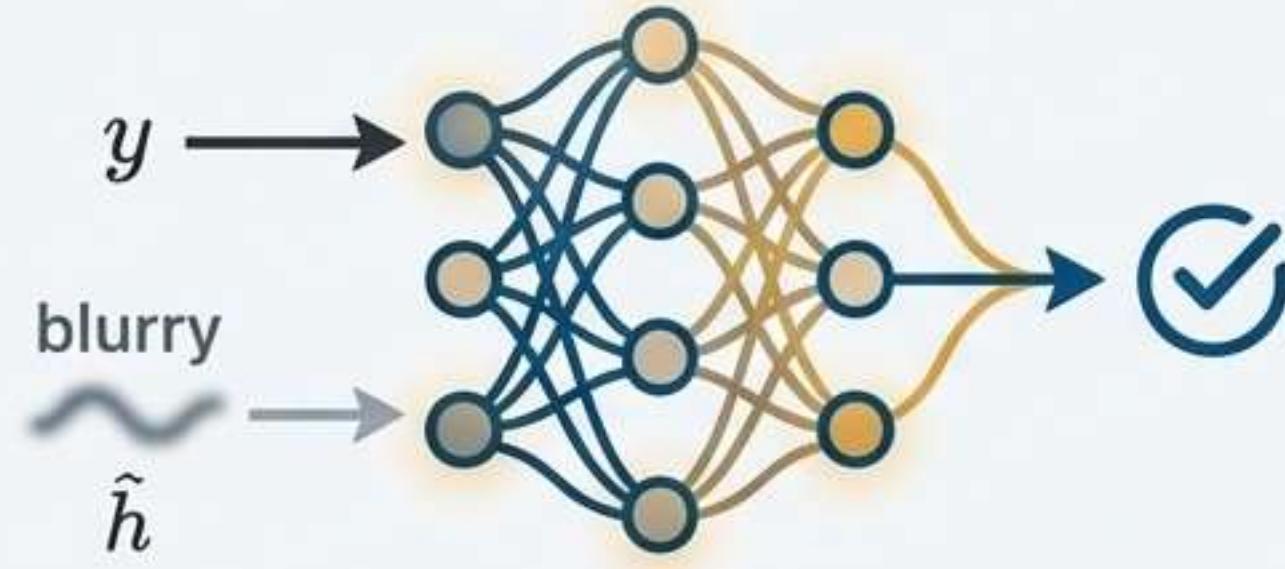
Mismatched Detector (Η Αδυναμία)



Εφαρμόζει έναν σταθερό, γραμμικό κανόνα εξισορρόπησης (y / \hat{h}) βασισμένο σε μια λανθασμένη παραδοχή (ότι $\hat{h} = h$).

- Το σφάλμα στην εκτίμηση \hat{h} διαδίδεται απευθείας στην απόφαση, προκαλώντας σφάλματα.

Neural Receiver (Η Δύναμη)



Δεν έχει προκαθορισμένο κανόνα.

- Λαμβάνοντας ως είσοδο τόσο το y όσο και το \hat{h} , μαθαίνει μια μη-γραμμική συνάρτηση που εκμεταλλεύεται οτατιοτικά τη σχέση μεταξύ του σήματος, του θορύβου και του σφάλματος εκτίμησης.
- Ουσιαστικά, 'μαθαίνει να δυσπιστεί' στην εκτίμηση \hat{h} και να προσαρμόζει την απόφασή του ανάλογα.

Βασικά Συμπεράσματα: Η Υπόσχεση των Νευρωνικών Δεκτών



Συμπέρασμα 1: Επιβεβαίωση Ορθότητας

Σε ιδανικές συνθήκες (AWGN), τα MLP μπορούν να αναπαράγουν πλήρως τον θεωρητικά βέλτιστο ανιχνευτή.



Συμπέρασμα 2: Ανθεκτικότητα σε Ρεαλιστικές Συνθήκες

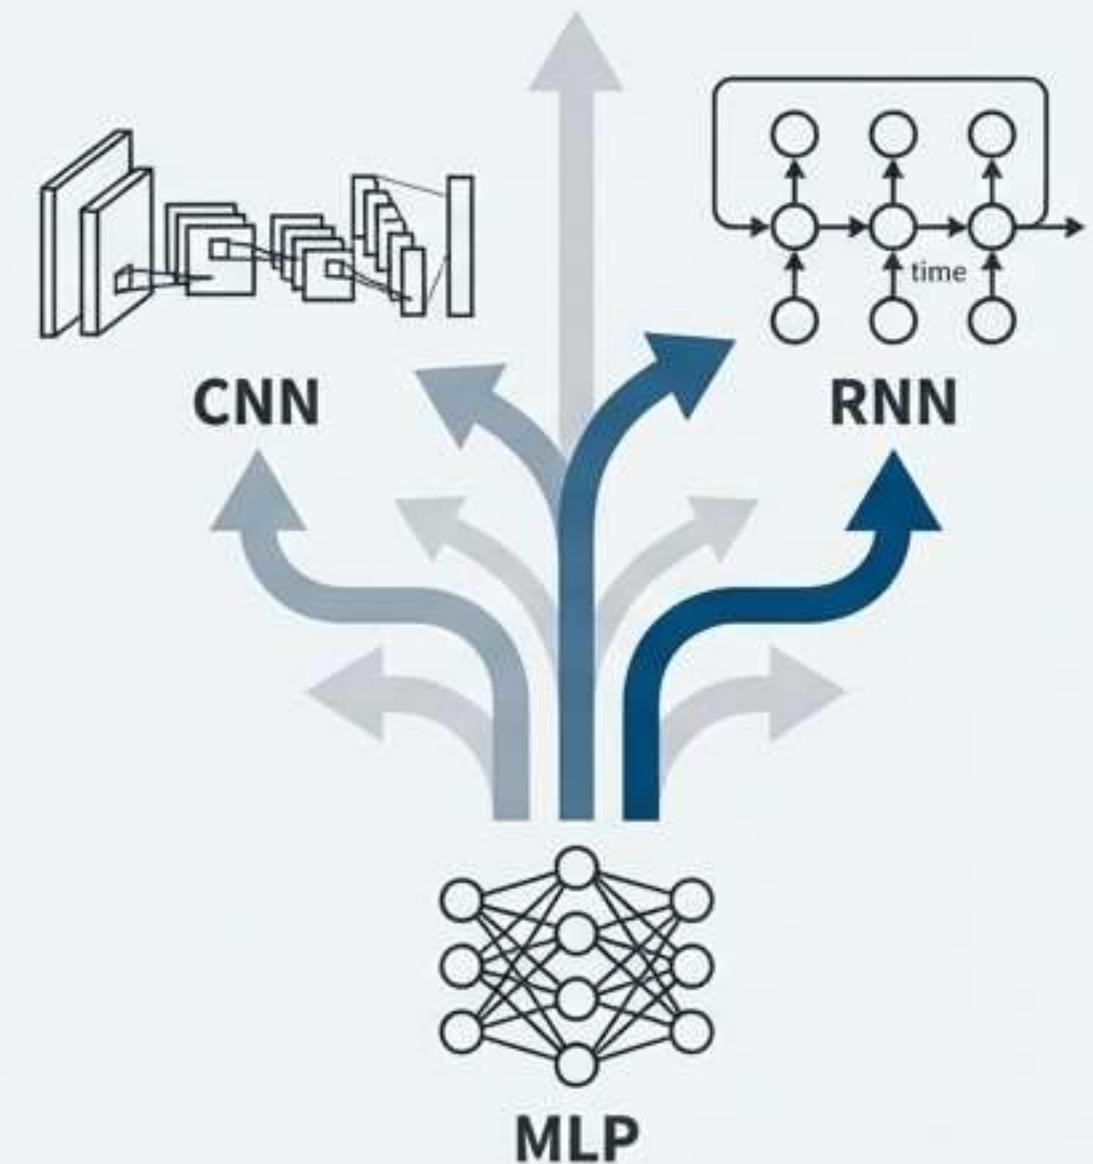
Σε κανάλια Rayleigh fading με ατελή γνώση καναλιού (imperfect CSI), τα MLP μπορούν να μάθουν πιο ανθεκτικούς κανόνες απόφασης και να ξεπεράσουν σε απόδοση τους κλασικούς mismatched ανιχνευτές.

Γενικό Συμπέρασμα: Τα μοντέλα Μηχανικής Μάθησης αποτελούν μια πολλά υποσχόμενη και ισχυρή εναλλακτική για τον σχεδιασμό δεκτών σε σύγχρονα και μελλοντικά συστήματα επικοινωνιών.

Επόμενα Βήματα και Μελλοντικές Κατευθύνσεις

Η προσέγγιση αυτή ανοίγει τον δρόμο για περαιτέρω έρευνα:

- **Εκπαίδευση σε Εύρος SNR:** Αντί για ένα σταθερό σημείο, η εκπαίδευση μπορεί να γίνει σε πολλαπλά επίπεδα θορύβου για τη δημιουργία πιο γενικευμένων δεκτών.
- **Πιο Σύνθετα Κανάλια:** Επέκταση σε κανάλια με επιλεκτικότητα στη συχνότητα (frequency-selective) και σε συστήματα OFDM.
- **Προηγμένες Αρχιτεκτονικές:** Διερεύνηση της χρήσης Συνελικτικών (CNN) ή Αναδρομικών (RNN) Δικτύων για την ανίχνευση ολόκληρων ακολουθιών συμβόλων.



Η μηχανική μάθηση δεν αντικαθιστά, αλλά συμπληρώνει τη θεωρία των επικοινωνιών, ειδικά σε περιπτώσεις όπου τα κλασικά μοντέλα δεν είναι πλήρως ακριβή.